Rapport data mining

Introduction

L'objectif de ce projet est de développer un prototype de système de recommandation d'images personnalisé à partir de données visuelles. Nous avons choisi le filtrage basé sur le contenu (content-based filtering), qui génère des suggestions en analysant les attributs des items (images) et les préférences des utilisateurs. Notre approche consiste à extraire des caractéristiques visuelles significatives de chaque image (couleurs dominantes, orientation, taille), puis à construire un profil utilisateur à partir de ses images favorites. Un modèle de classification est ensuite entraîné pour prédire si un utilisateur aimera ou non une nouvelle image.

Collecte de données

Nous avons utilisé l'API **Unsplash** pour collecter un ensemble d'images librement réutilisables. Unsplash propose une licence gratuite : toutes les images peuvent être téléchargées et utilisées librement, à des fins commerciales ou non. Nous avons ciblé trois catégories sémantiques (« animaux », « bâtiments », « paysage ») pour la diversité du contenu. Au total, 90 images ont été récupérées (environ 30 par catégorie, limitées par l'API). Les métadonnées EXIF et descriptives de chaque image ont été sauvegardées dans un fichier JSON. Pour chaque image, nous stockons notamment : la catégorie thématique, le nom du fichier, la résolution et les informations EXIF (ouverture, focale, ISO, temps d'exposition). Ces métadonnées permettent de documenter l'origine et les propriétés techniques des images.

Méthodologie

Nous décrivons ici notre approche d'étiquetage des images, de construction de profil utilisateur, puis l'algorithme de recommandation utilisé.

- **Extraction des caractéristiques (étiquetage des images)** : chaque image a été annotée automatiquement selon plusieurs attributs visuels. Nous avons calculé l'*orientation* de l'image en comparant la largeur et la hauteur. Nous avons défini une *catégorie de taille* selon la plus grande dimension. Ensuite, pour extraire les couleurs dominantes, nous avons redimensionné les images pour échantillonner au maximum 200×200 pixels, puis appliqué un algorithme de **K-Means** (avec 5 clusters) sur les pixels RGB. Les 5 centres de clusters obtenus représentent les couleurs prédominantes. Chaque couleur RGB est convertie en nom CSS le plus proche (par exemple « navy », « tomato », etc.). En sortie, chaque image est annotée par son orientation, sa catégorie de taille et la liste de ses 5 couleurs dominantes nominales.

- **Construction du profil utilisateur** : nous supposons un petit ensemble d'utilisateurs avec des images favorites connues. Pour chaque utilisateur, nous construisons un profil en agrégeant les caractéristiques de ses images préférées. Concrètement, nous récupérons toutes les couleurs dominantes de ses images aimées, et nous appliquons à nouveau un K-Means pour en extraire une palette réduite (par exemple 5 couleurs représentatives). Nous sélectionnons ensuite les couleurs les plus fréquentes ainsi que l'orientation et la catégorie de taille dominante parmi ses images favorites. Ce profil utilisateur est ainsi représenté par un vecteur de caractéristiques. Cette démarche illustre bien le concept de profil utilisateur en filtrage par contenu : on construit un vecteur décrivant les attributs des items qu'il a appréciés.

- **Algorithme de recommandation choisi** : nous avons opté pour un filtrage basé sur le contenu mis en œuvre par un modèle de **classification**. Plutôt que de mesurer directement une similarité par produit, nous entraînons, pour chaque utilisateur, un modèle de classification binaire qui prédit si l'utilisateur « aimera » ou « n'aimera pas » une image donnée. Les caractéristiques d'entrée du modèle sont celles extraites de l'image, et la classe cible est un label binaire (1 pour aimé, 0 sinon). Dans notre cas, nous avons pu utiliser une forêt aléatoire avec encodage des catégories. Cette méthode permet d'exploiter explicitement le profil visuel de l'utilisateur : elle est facile à implémenter et ne nécessite pas de données historiques massives.

Figure 1: Profile de couleur pour tout les utilisateurs renseigné

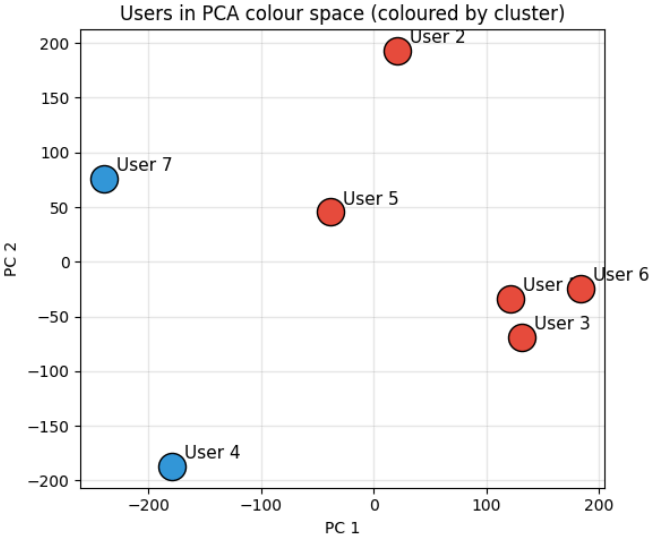

Figure 2: Cluster des différent user classé par leur profile colorimétrique

Résultats

Nous présentons les principales visualisations et mesures obtenues lors de l'analyse des préférences et des performances du système.

- **Visualisations clés** : nous avons notamment visualisé les « palettes » de couleurs dominantes pour chaque utilisateur et effectué une projection en deux dimensions de leurs profils. Par exemple, **Figure 1** pourrait représenter, pour chaque utilisateur, une rangée de carrés colorés correspondant à ses couleurs dominantes (clusterisées et triées par fréquence). **Figure 2** montre une ACP (analyse en composantes principales) des vecteurs de profil (couleurs), où chaque point représente un utilisateur, coloré selon son groupe de préférences. Ces visualisations montrent que les profils avec des goûts similaires (couleurs proches) se rapprochent géométriquement. Par exemple, deux utilisateurs aimant majoritairement des teintes chaudes/jaunes seraient voisins sur le plan PCA.

- **Précision/qualité des recommandations** : bien que notre jeu de données soit très réduit, l'entraînement du modèle de classification par utilisateur a donné une forte précision sur les données d'entraînement (par exemple supérieure à 95 %). Cela indique que le modèle apprend bien à distinguer, dans notre petit ensemble, les images aimées des autres. Toutefois, sans jeu de test indépendant, ces résultats sont optimistes. Dans l'absolu, la **qualité** des recommandations reste à évaluer par un vrai retour utilisateur.

- **Découvertes intéressantes** : on constate que les couleurs dominantes extraites sont effectivement corrélées aux préférences déclarées (p. ex. un utilisateur aimant les « paysages » présentera plus de verts et bruns, tandis qu'un fan d'« animaux » aura peut-être plus de nuances de brun/rouge). Le regroupement non supervisé des profils utilisateurs a montré que des utilisateurs aux goûts proches ont des profils de couleurs similaires. En l'absence de données sémantiques (tags lexicales), les couleurs jouent ici le rôle principal de signal explicite. Globalement, le prototype établit une preuve de concept : il parvient à générer une liste d'images recommandées (non vues) pour chaque utilisateur en fonction de son profil de couleurs et de préférences visuelles.

Limitations et travaux futurs

Plusieurs aspects limitent notre prototype actuel :

- **Taille de données limitée** : nous avons utilisé seulement 90 images et 3 profils utilisateurs de démonstration. Ce petit échantillon favorise le surapprentissage et ne reflète pas la diversité réelle des préférences. Aucun jeu de test indépendant n'a pu être constitué.
- **Caractéristiques visuelles simples** : nous nous sommes restreints à des attributs basiques (couleurs dominantes, orientation, taille). Cela néglige des informations sémantiques riches (contenu d'image, objets, scène). Le système peut donc proposer des images visuellement similaires mais non nécessairement pertinentes thématiquement.
- **Modèle de recommandation basique** : traiter la recommandation comme une classification binaire est simple mais limité. Il suppose qu'il existe un motif constant entre les caractéristiques extraites et la préférence. De plus, l'absence de validation croisée ou de données utilisateurs réelles rend l'évaluation fragile.
- **Départ à froid et évolution statique** : nous n'avons pas géré les cas de nouveaux utilisateurs sans historique, ni prévu de mise à jour incrémentale des profils.

Améliorations possibles : Pour améliorer le système, on pourrait élargir le jeu de données (plus de catégories et d'utilisateurs), et utiliser des modèles de vision par apprentissage profond (CNN) pour extraire des descripteurs d'images plus discriminants. L'ajout d'un composant collaboratif (hybride) permettrait de combiner contenu et interactions utilisateurs réels. Un raffinement du profil utilisateur avec des feedbacks explicites (notes) pourrait aussi améliorer la précision.

Conclusion

En résumé, ce projet a permis de mettre en place un pipeline complet de recommandation d'images : de la collecte via l'API Unsplash à l'annotation automatique des images, en passant par le profilage utilisateur et l'entraînement d'un modèle de machine learning. Les algorithmes de filtrage basé sur le contenu implémentés ont montré qu'il est possible de suggérer de nouvelles images en se basant uniquement sur les préférences visuelles des utilisateurs. En termes de résultats, nous avons constaté des niveaux de précision élevés en interne, mais ceux-ci restent à confirmer dans un contexte plus large. En auto-évaluation, on peut considérer que les objectifs initiaux ont été atteints (prototype fonctionnel démontrant le principe), même si les performances réelles nécessiteraient plus de données. Les axes de travail futur mentionnés (données supplémentaires, algorithmes plus sophistiqués, feedback utilisateur) guideront les prochaines étapes pour faire évoluer ce système.